

프로젝트 문제정의 계획서

20242513 김명서

1. 선택한 데이터

- 데이터 이름: KBO Player Dataset (1982-2025)
중에서 kbo_batting_stats_by_season_1982-2025
- 출처(URL): <https://www.kaggle.com/datasets/netsong/kbo-player-dataset-by-regular-season-1982-2025>
- 라이선스: CC0: Public Domain
- 크기: 약 9,731행 × 39열
- 형식: CSV
- 어떻게 받았나: Kaggle 사이트에서 CSV 파일 다운로드

2. 풀고 싶은 문제

- 요약: KBO 타자 데이터를 활용해 WAR에 영향을 미치는 주요 타격 지표를 분석하고, 이전 시즌 기록을 기반으로 다음 시즌 WAR를 예측한다.
- 예측/분류 대상(Target): WAR (Wins Above Replacement)
(WAR는 야구에서 선수의 종합적인 팀 승리 기여도를 나타내는 대표 지표로 사용된다.)

3. 만들 서비스(완성 모습)

- 서비스명: 규정타석 이상 KBO 타자 WAR 분석 및 WAR 예측 플랫폼
- 서비스 설명: - 사용자가 선수 이름을 입력하면 해당 선수의 주요 기록을 시각적으로 분석해주고, 성적 데이터를 입력하면 예상 WAR를 예측해주는 웹 서비스이다.
- 선수 선택 기반 조회 + 비슷한 선수 추천 + 다음 시즌 예상 WAR 제공
- 24년도까지 데이터는 학습셋, 25년도 데이터는 데이터셋

기본 제공	서비스 제공
선수 이름	선수 기록 조회
타율(AVG)	선수 가치(WAR) 분석
홈런(HR)	OPS와 WAR 관계 시각화
타점(RBI)	홈런과 WAR 관계 시각화
도루(SB)	예상 WAR 예측
OPS	유사 선수 추천
wRC+	
나이(Age)	

- 사용할 기술
 1. Machine Learning (Random Forest Regressor, KNN (유사 선수 추천))
 2. Streamlit (데이터 시각화, 대시보드 웹 서비스 구현)모델: 선형회귀, Random Forest, XGBoost 계열 중 2~3개 비교를 고려하고, KNN은 별도의 추천 기능으로 분리한다.

4. 예상 난관 1가지

WAR는 여러 기록이 복합적으로 반영된 파생지표일 뿐만 아니라 시즌별 환경 차이, 포지션 간 편차, 결측치 등 고려해야 할 변수가 많아 단순한 성적만으로 정확하게 예측하기 어렵다. 이를 해결하기 위해 변수 간 상관관계 분석과 Feature Importance 분석을 수행하여 WAR에 영향을 주는 주요 요인을 파악하고 모델 성능을 개선할 계획이다.