

KBO 타자 WAR 분석 및 다음 시즌 WAR 예측 플랫폼

이름 / 학번: 김명서 / 20242513

데이터 출처: KBO Player Dataset (1982-2025) — Kaggle (netsong)

URL: <https://www.kaggle.com/datasets/netsong/kbo-player-dataset-by-regular-season-1982-2025>

라이선스: CC0 (Public Domain)

1. 문제 정의

■ 분석 배경 및 목적

WAR(Wins Above Replacement)는 야구에서 선수가 대체선수 대비 팀 승리에 얼마나 기여했는가를 단일 숫자로 표현하는 종합 지표로, 타격·주루·수비를 모두 반영한다. KBO는 미국 메이저리그와 달리 WAR 관련 분석 서비스가 제한적이어서, 일반 팬이 선수의 가치를 직관적으로 파악하기 어렵다는 문제가 있다.

본 프로젝트는 1982-2025년 KBO 타자 데이터를 활용해 두 가지 문제를 해결한다.

- 분석: WAR에 영향을 미치는 주요 타격 지표를 시각적으로 탐색한다.
- 예측: 현재 시즌의 성적 기록을 입력받아 다음 시즌 WAR를 수치로 예측한다.

■ 예측 대상 (Target)

- Target: next_WAR — 다음 시즌의 WAR 값 (연속형 회귀 문제)
- 입력(Feature): 현재 시즌의 타격 성적 21개 변수
(WAR, oWAR, dWAR, AVG, OBP, SLG, OPS, HR, RBI, SB, BB, SO, wRC+, Age, G, PA, R, H, 2B, 3B, TB)

2. 데이터 소개 & EDA





2-1. 데이터 규모 및 형식

항목	내용
파일명	kbo_batting_stats_by_season_1982-2025.csv
크기	9,731행 × 39열
형식	CSV (UTF-8 인코딩)
수록 기간	1982-2025시즌 (44년)
등록 선수 수	1,836명 (시즌별 중복 포함)
결측치	WAR 컬럼 결측 없음 (0건)

주요 컬럼 설명

- WAR: 종합 WAR (oWAR + dWAR)
- oWARdWAR: 공격 기여 WAR / 수비 기여 WAR
- AVGOBPSLGOPS: 타율 / 출루율 / 장타율 / OPS
- HRRBISB: 홈런 / 타점 / 도루
- wRC+: 리그·구장 보정 득점 생산력 (100 = 리그 평균)
- PA: 타석 수

2-2. EDA에서 발견한 주요 사실



① 규정타석(PA ≥ 300) 필터링의 중요성

전체 9,731개 레코드 중 PA ≥ 300인 규정타석 이상 레코드는 **2,739개(28.1%)**이다. 소수 타석 선수를 포함하면 WAR 분포가 0 부근에 심하게 집중되어(전체 평균 WAR = 0.78) 분석이 왜곡된다. 규정타석 이상으로 제한하면 평균 WAR = 2.59로 의미 있는 분석이 가능하다.

② wRC+·OPS가 WAR와 가장 높은 상관관계

규정타석 이상 선수를 대상으로 계산한 피어슨 상관계수다.

지표	WAR와 상관계수
wRC+	0.849
OPS	0.778
OBP (출루율)	0.767
SLG (장타율)	0.706
AVG (타율)	0.664
HR / ISO	0.565
SB (도루)	0.196
Age (나이)	-0.067
SO_rate (삼진율)	-0.143

→ 리그·구장 보정이 이미 반영된 wRC+가 WAR를 가장 잘 설명하며, 단순 타율(AVG)보다 출루율(OBP)이 더 중요함을 확인했다. 나이와 WAR는 약한 음의 상관을 보여 **고령 선수일수록 평균 WAR가 소폭 낮아지는 경향**이 있다.

③ 연도별 리그 평균 WAR는 2.4-2.8 수준으로 안정적

2016-2025시즌 리그 평균 WAR (규정타석 이상):

시즌	평균 WAR
2016	2.43
2018	2.45
2020	2.84
2022	2.62
2024	2.39
2025	2.61

→ 2020년 코로나 축소 시즌에 평균 WAR가 일시적으로 높게 나타난 점, 10구단 체제(2015년~) 이후 선수풀 희석으로 평균이 소폭 낮아진 점이 눈에 띈다.

2-3. 결측치 및 이상치 처리

처리 항목	방법
WAR 결측	없음 (0건) — 별도 처리 불필요
PA = 0인 레코드	clean()함수에서 제거 (0타석 선수 제외)
BABIP 분모 = 0	replace(0, np.nan)으로 처리 후 NaN 유지
다음 시즌 WAR 생성	연속 시즌 쌍만 유효 — 연도 공백(부상·은퇴 후 복귀)이 있는 경우 제외

3. 특성 엔지니어링

3-1. 파생 변수 생성 (src/features.py)

원시 데이터의 절대값 지표(HR, RBI 등)는 출전 경기 수에 비례하므로, 비율 기반 파생 변수를 추가해 선수 간 비교 가능성을 높였다.

파생 변수	계산식	추가 근거
BB_rate	$BB \div PA$	볼넷 선구안 능력 — 출루율의 핵심 구성 요소
SO_rate	$SO \div PA$	삼진율 — 높을수록 컨택 능력 부족, WAR 음의 상관
ISO	$SLG - AVG$	순수 장타력 지표, HR과 유사하지만 2루·3루타도 반영
BABIP	$(H - HR) \div (AB - SO - HR + SF)$	인플레이 타구 안타율 — 운·수비 환경 보정 지표

3-2. 다음 시즌 WAR 예측용 데이터셋 구성 (build_next_war_dataset)

처리 단계	내용
① 규정타석 필터	PA ≥ 300인 레코드만 사용
② 시간 순 정렬	선수 ID별로 Year 오름차순 정렬
③ Lag 변수 생성	현재 시즌 WAR를 기준으로 다음 시즌 WAR(next_WAR) 생성
④ 연속 시즌 검증	next_Year == Year + 1조건으로 연도 공백 제거
⑤ 최종 데이터셋	학습 1,689쌍 (-2022년) + 테스트 56쌍 (2023시즌)

4. 모델 / 서비스

4-1. 사용 방법 및 선택 근거

머신러닝 회귀 모델 3종 비교 (scikit-learn + XGBoost)

모델	선택 이유
Linear Regression	기준선(Baseline) 모델, 결과 해석이 용이함
Random Forest	비선형 관계 학습, 이상치 강건성, Feature Importance 제공
XGBoost	순차 부스팅으로 잔차 보정, 작은 데이터셋에서도 강력한 성능

딥러닝/LLM을 사용하지 않은 이유: 타구조 수치 데이터 회귀 문제로 해석 가능성이 높은 전통 ML이 적합하며, 학습 샘플 수(~1,700개)가 딥러닝에 충분하지 않다.

KNN (K-Nearest Neighbors) — 유사 선수 추천 전용

타격 지표 10개(AVG, OBP, SLG, OPS, HR, RBI, SB, BB, SO, wRC+)를 정규화 후 유클리드 거리 기준으로 가장 유사한 5명을 추천한다.

4-2. 입력 → 출력 흐름



4-3. 모델 성능 지표 (테스트셋: 2023시즌 → 2024시즌 예측)

모델	MAE	RMSE	R²
Linear Regression	1.146	1.479	0.292
XGBoost	1.277	1.570	0.202
Random Forest	1.265	1.618	0.152

최고 성능 모델: Linear Regression (R² = 0.292)

해석: MAE 약 1.15 WAR - 예측값이 실제 다음 시즌 WAR와 평균 1.15승 내외 오차를 보인다. 다음 시즌 WAR 예측은 부상, 이적, 나이에 따른 변화 등 모델이 학습할 수 없는 외부 요인이 많아 본질적으로 어려운 문제이며, R^2 0.3 수준은 이 과제에서 현실적인 성능이다.

Random Forest Feature Importance (상위 5개)

1. WAR (현시즌): 0.245
2. Age (나이): 0.062
3. BB (볼넷): 0.049
4. SO (삼진): 0.044
5. oWAR (공격 WAR): 0.044

→ 현재 시즌 WAR가 다음 시즌 WAR를 예측하는 가장 강력한 변수임이 확인됐다 (중요도 0.245, 2위 Age의 4배). 이는 선수의 실력이 단기간에 크게 변하지 않는다는 야구 통계의 일반 원칙과 일치한다. 나이(Age)가 2위를 차지한 것은 에이징 커브(성장·노화)를 모델이 포착하고 있음을 시사한다.

5. Streamlit 앱

5-1. 페이지 구성

```
Home.py          ← 홈 화면 (서비스 소개 + 데이터 미리보기)
pages/
  1. 탐색적 데이터 분석 (EDA).py      ← 탐색적 데이터 분석
  2. KBO 타자 성적 시각화.py          ← 선수별 시각화
  3. WAR 예측 모델 및 서비스.py       ← 예측 모델 + 유사 선수 추천
src/
  data_loader.py    ← 데이터 로드 (캐싱)
  features.py       ← 전처리 + 피처 엔지니어링
data/
  kbo_batting_stats_by_season_1982-2025.csv
```

5-2. 페이지별 주요 기능

홈 (app.py)

- 서비스 목적 소개 및 페이지 안내
- 핵심 수치 지표 카드 (전체 레코드, 선수 수, 수록 시즌, 규정타석 레코드 수)
- 최근 5년 데이터 미리보기 테이블
- 사이드바 용어 사전 기능: 세이버메트릭스 지표에 익숙하지 않은 사용자의 이해를 돕기 위해, 모델에 사용된 21개 주요 타격 지표를 4가지 카테고리(종합 지표, 비율 지표, 카운트 지표, 기본 지표)로 분류하여 직관적인 설명을 제공하는 아코디언(Expander) 메뉴를 구현함.

Home

탐색적 데이터 분석 (EDA)

KBO 타자 성적 시각화

WAR 예측 모델 및 서비스

KBO WAR Proejct

Big Data Analysis & Prediction

용어 사전 (Terminology)

[핵심 종합 지표]

WAR: 대체 선수 대비 승리 기여도 (종합)

oWAR: 공격 기여 WAR (Offensive)

dWAR: 수비 기여 WAR (Defensive)

wRC+: 조정 득점 생산력 (100이 리그 평균)

[타격 비율 지표]

AVG: 타율 (Batting Average)

Deploy

🕒 KBO 타자 WAR 분석 및 예측 플랫폼

규정타석 이상 KBO 타자의 WAR(Wins Above Replacement)를 분석하고, 이전 시즌 성적을 기반으로 다음 시즌 WAR를 예측하는 웹 서비스입니다.

페이지	내용
1. 탐색적_데이터_분석	데이터 탐색 — 분포, 상관관계, 결측치 확인
2. 다차원_통계_시각화	선수별 커리어 추이, OPS+HR vs WAR 산점도
3. WAR_예측_모델_및_서비스	WAR 예측·모델 비교·유사 선수 추천

왼쪽 사이드바에서 페이지를 선택하세요.

전체 레코드

선수 수 (통산)

수록 시즌

규정타석(PA≥300) 레코드

9,731행

1,836명

1982 – 2025

2,739행

데이터 미리보기 (최근 5년)

	Year	Name	Team	Pos.	Age	G	PA	AVG	OPS	HR	RBI	SB	wRC+	WAR
0	2025	송성문	키움	3B	29	144	646	0.315	0.917	26	90	25	164.1	8.58
1	2025	양의지	두산	C	38	130	517	0.337	0.939	20	89	4	162.8	6.79
2	2025	안현민	KT	RF	22	112	482	0.334	1.018	22	80	7	182.7	6.77
3	2025	김조원	NC	SS	22	144	624	0.288	0.873	15	65	44	121.1	6.33

1_EDA 페이지

사이드바: 최소 PA 슬라이더(0~600) + 시즌 범위 슬라이더

① 데이터 기본 정보 + 결측치 현황

② WAR 히스토그램 + 연도별 WAR 박스플롯

③ 주요 지표 상관관계 히트맵 (피어슨 r, 컬러맵)

④ WAR와 각 지표의 상관계수 가로 막대그래프

⑤ 포지션별 WAR 박스플롯

⑥ 원시 데이터 탐색 테이블

Home

탐색적 데이터 분석 (EDA)

KBO 타자 성적 시각화

WAR 예측 모델 및 서비스

필터

최소 PA (타석)

300

시즌 범위

2000

2025

🔍 Stop Deploy

📊 탐색적 데이터 분석 (EDA)

① 데이터 기본 정보

필터 후 레코드

선수 수

결측치 (WAR)

WAR 평균

1,881

411

0

2.57

> 컬럼별 결측치 현황

> 기술통계 (주요 타격 지표)

② WAR 분포

WAR 히스토그램 (PA≥300)

연도별 WAR 분포

WAR 히스토그램 (PA≥300)은 WAR의 분포를 보여줍니다. x축은 WAR, y축은 Count입니다. 평균 2.57이 표시되어 있습니다.

연도별 WAR 분포는 연도에 따른 WAR의 분포를 보여줍니다. x축은 연도, y축은 WAR입니다.

2_시각화 페이지

탭 1 - 선수 커리어: 선수 선택 → WAR 추이 막대+선 그래프, AVG·OBP·SLG 추이, HR·RBI·SB 추이

탭 2 - OPS·HR vs WAR: 산점도(OLS 추세선 포함), wRC+ vs WAR

탭 3 - 연도·팀 트렌드: 리그 평균 지표 추이, 팀별 평균 WAR 막대그래프

탭 4 - 시즌 TOP: 시즌·N명 선택 → WAR 순위 테이블 + 가로 막대그래프



3_모델_서비스 페이지


탭 1 - 모델 성능 비교: MAE·RMSE· R^2 비교 테이블, 실제 vs 예측 산점도, RF Feature Importance 막대그래프

탭 2 - WAR 예측: 성적 입력 폼(21개 변수)

→ 예상 WAR + 등급 판정 + 비슷한 WAR 선수 사례

탭 3 - 유사 선수 추천: 선수 선택 또는 직접 입력

→ KNN 유사 선수 5명 + 레이더 차트 비교



<WAR 예측: 성적 입력 폼을 통한 예상 WAR 및 선수 등급 판정 도출>

🔍 성적 입력 → 다음 시즌 예상 WAR 예측

현재 시즌 성적을 입력하면 다음 시즌 WAR도 예측합니다.

사용 방법

Random Forest (선택) XGBoost Linear Regression

현재 시즌 WAR (가장 중요한 예측 변수)

WAR (총합) - + 0.69 uWAR (중계 WAR) - + 0.01 oWAR (우익 WAR) - +

타격 지표 입력

타율 (AVG) 0.227 - + 0.296 - + 0.327 - + 0.622 - +

출루율 (OBP) 타점 (RBI) 도루 (SB) OPS

3 - + 21 - + 3 - + 16 - +

상진 (SO) wRC+ 나이 (Age) 경기 수 (G)

36 - + 69 - + 27 - + 60 - +

타석 (PA) 득점 (R) 안타 (H) 2루타 (2B)

185 - + 22 - + 42 - + 7 - +

3루타 (3B) 유타 (TB)

0 - + 63 - +

WAR 예측하기

예상 다음 시즌 WAR: 1.55

평가: 📈 백업 (0.5-2.0)

비슷한 WAR 선수 사례 참고

Year	Name	Team	AVG	OPS	RBI	wRC+	WAR
0	2025 정준제	SSG	0.245	0.628	18	0	91.7
1	2025 장혁호	KT	0.265	0.625	15	128.9	1.68

<유사 선수 추천: KNN 알고리즘 기반 유사 선수 5명 추천 및 레이더 차트 비교>

🔍 유사 선수 추천 (KNN 기반)

타격 지표: 타율, 출루율, 타점, 득점, 안타, 2루타, 3루타, 홈런, OPS, wRC+, WAR

검색 방법

선수 검색 직접 입력

시즌

2024

선수

김도형

선택 선수 기록

Name	Year	Team	Pos	Age	PA	AVG	OBP	SLG	OPS	RBI	SB	CS	BB	SO	wRC+	WAR
김도형	2024	KIA	3B	25	625	0.347	0.42	0.647	1.067	38	339	41	68	120	172.5	8.58

유사 선수 찾기

유사 선수 5명 추천

Name	Year	Team	Pos	Age	PA	AVG	OBP	SLG	OPS	RBI	SB	CS	BB	SO	wRC+	WAR
0 정준제	1991	LG	3B	33	558	0.345	0.45	0.64	1.09	35	134	21	76	88	204.3	7.23
1 박지환	2000	LG	CF	27	572	0.309	0.388	0.589	0.977	22	121	39	64	77	150.3	5.26
2 홍현우	1990	NC	3B	37	961	0.3	0.362	0.603	0.965	34	121	31	64	104	136.6	5.51
3 송시환	2000	LG	CF	27	539	0.338	0.409	0.622	1.031	32	95	29	52	72	189.4	5.61
4 김도형	2024	KIA	3B	25	529	0.321	0.427	0.679	1.106	49	121	33	74	103	170.7	5.15

레이더 차트 비교

타격 지표 레이더 차트 비교



5-2. 실행 방법 및 주요 패키지

1. 의존성 패키지 설치

`pip install -r requirements.txt`

2. 앱 실행 (프로젝트 폴더 내에서 실행)

`streamlit run app.py`

주요 패키지: streamlit, pandas, numpy, plotly, scikit-learn, xgboost

6. 결론 & 한계

6-1. 알게 된 것

1. WAR 예측의 핵심 변수는 현재 시즌 WAR 자체다

Feature Importance 분석에서 현시즌 WAR가 1위(0.245)로 나타나 선수의 실력이 단기간에 급변하지 않음을 입증했다.

2. 출루율(OBP)이 타율(AVG)보다 WAR와 더 강하게 연관된다

출루율을 중시하는 세이버메트릭스의 주장이 KBO 데이터($OBP\ 0.767 > AVG\ 0.664$)에서도 확인되었다.

3. wRC+는 WAR의 가장 강력한 단일 예측 지표다

상관계수 0.849로 가장 높게 나타났다.

4. 나이(Age)와 WAR의 관계

전체 데이터 수준에서 고령 선수일수록 평균 WAR가 낮아지는 경향(-0.067)이 관찰된다.

5. 예측의 불확실성

부상, 이적, 팀 환경 변화 등 모델이 학습할 수 없는 요인으로 인해 다음 시즌 WAR 예측에는 본질적인 한계가 존재한다.

6-2. 한계 및 향후 과제

한계	내용
테스트셋 규모	규정타석 기준 적용 시 시즌당 56명 수준으로 작아 성능 평가의 분산이 큼
시즌 환경 차이	지명타자 운용, 외국인 선수 수, 10구단 확장 등 리그 환경 변화 미반영
포지션 미반영	포지션별(포수 vs 1루수 등) WAR 가중치 차이가 모델에 인코딩되지 않음
부상 정보 부재	부상, 군입대, 방출 등 다음 시즌 출전 가능 여부를 예측하는 외부 변수 부재

향후 개선 방향

- 포지션 원-핫 인코딩 추가 및 포지션별 별도 모델 학습
- 선수 에이징 커브(나이별 WAR 평균 궤적) 피쳐 추가
- 최근 3년치 성적의 가중 평균을 피쳐로 활용
- 시계열 교차 검증(TimeSeriesSplit) 도입 및 투수 데이터 확장 적용
- 투수 데이터까지 확장하여 팀 WAR 예측 서비스 구현