

KBO 타자 WAR 분석 및 다음 시즌 WAR 예측 플랫폼

이름 / 학번: 김명서 / 20242513

데이터 출처: KBO Player Dataset (1982-2025) - Kaggle (netsong)

URL: <https://www.kaggle.com/datasets/netsong/kbo-player-dataset-by-regular-season-1982-2025>

라이선스: CC0 (Public Domain)

1. 문제 정의

■ 분석 배경 및 목적

WAR(Wins Above Replacement)는 야구에서 선수가 대체선수 대비 팀 승리에 얼마나 기여했는가를 단일 숫자로 표현하는 종합 지표로, 타격·주루·수비를 모두 반영한다. KBO는 미국 메이저리그와 달리 WAR 관련 분석 서비스가 제한적이어서, 일반 팬이 선수의 가치를 직관적으로 파악하기 어렵다는 문제가 있다.

본 프로젝트는 1982-2025년 KBO 타자 데이터를 활용해 두 가지 문제를 해결한다.

분석: WAR에 영향을 미치는 주요 타격 지표를 시각적으로 탐색한다.

예측: 현재 시즌의 성적 기록을 입력받아 다음 시즌 WAR를 수치로 예측한다.

■ 예측 대상 (Target)

Target: next_WAR - 다음 시즌의 WAR 값 (연속형 회귀 문제)

입력(Feature): 현재 시즌의 타격 성적 21개 변수

(WAR, oWAR, dWAR, AVG, OBP, SLG, OPS, HR, RBI, SB, BB, SO, wRC+, Age, G, PA, R, H, 2B, 3B, TB)

2. 데이터 소개 & EDA

2-1. 데이터 규모 및 형식

항목	내용
파일명	kbo_batting_stats_by_season_1982-2025.csv
크기	9,731행 × 39열
형식	CSV (UTF-8 인코딩)
수록 기간	1982-2025시즌 (44년)
등록 선수 수	1,836명 (시즌별 중복 포함)
결측치	WAR 컬럼 결측 없음 (0건)

주요 컬럼 설명

WAR: 종합 WAR (oWAR + dWAR)

oWARdWAR: 공격 기여 WAR / 수비 기여 WAR

AVGOBPSLGOPS: 타율 / 출루율 / 장타율 / OPS


HRRBISB: 홈런 / 타점 / 도루

wRC+: 리그·구장 보정 득점 생산력 (100 = 리그 평균)


PA: 타석 수

2-2. EDA에서 발견한 주요 사실


② WAR 분포




③ 주요 지표 상관관계 히트맵



④ WAR와 주요 지표 상관 엑셀 그래프



⑤ 포지셔널 WAR 분포



① 규정타석(PA ≥ 300) 필터링의 중요성

전체 9,731개 레코드 중 PA ≥ 300인 규정타석 이상 레코드는 **2,739개(28.1%)**이다. 소수 타석 선수를 포함하면 WAR 분포가 0 부근에 심하게 집중되어(전체 평균 WAR = 0.78) 분석이 왜곡된다. 규정타석 이상으로 제한하면 평균 WAR = 2.59로 의미 있는 분석이 가능하다.

② wRC+·OPS가 WAR와 가장 높은 상관관계

규정타석 이상 선수를 대상으로 계산한 피어슨 상관계수다.

지표	WAR와 상관계수
wRC+	0.849
OPS	0.778
OBP (출루율)	0.767
SLG (장타율)	0.706
AVG (타율)	0.664
HR / ISO	0.565
SB (도루)	0.196
Age (나이)	-0.067
SO_rate (삼진율)	-0.143

→ 리그·구장 보정이 이미 반영된 wRC+가 WAR를 가장 잘 설명하며, 단순 타율(AVG)보다 출루율(OBP)이 더 중요함을 확인했다. 나이와 WAR는 약한 음의 상관을 보여 고령 선수일수록 평균 WAR가 소폭 낮아지는 경향이 있다.

③ 연도별 리그 평균 WAR는 2.4-2.8 수준으로 안정적

2016-2025시즌 리그 평균 WAR (규정타석 이상):

시즌	평균 WAR
2016	2.43
2018	2.45
2020	2.84
2022	2.62
2024	2.39
2025	2.61

→ 2020년 코로나 축소 시즌에 평균 WAR가 일시적으로 높게 나타난 점, 10구단 체제(2015년~) 이후 선수풀 희석으로 평균이 소폭 낮아진 점이 눈에 띈다.

2-3. 결측치 및 이상치 처리

처리 항목	방법
WAR 결측	없음 (0건) - 별도 처리 불필요
PA = 0인 레코드	clean()함수에서 제거 (0타석 선수 제외)
BABIP 분모 = 0	replace(0, np.nan)으로 처리 후 NaN 유지
다음 시즌 WAR 생성	연속 시즌 쌍만 유효 - 연도 공백(부상·은퇴 후 복귀)이 있는 경우 제외

3. 특성 엔지니어링

3-1. 파생 변수 생성 (src/features.py)

원시 데이터의 절대값 지표(HR, RBI 등)는 출전 경기 수에 비례하므로, 비율 기반 파생 변수를 추가해 선수 간 비교 가능성을 높였다.

파생 변수	계산식	추가 근거
BB_rate	$BB \div PA$	볼넷 선구안 능력 - 출루율의 핵심 구성 요소
SO_rate	$SO \div PA$	삼진율 - 높을수록 컨택 능력 부족, WAR 음의 상관
ISO	$SLG - AVG$	순수 장타력 지표, HR과 유사하지만 2루·3루타도 반영
BABIP	$(H - HR) \div (AB - SO - HR + SF)$	인플레이 타구 안타율 - 운·수비 환경 보정 지표

3-2. 다음 시즌 WAR 예측용 데이터셋 구성 (build_next_war_dataset)

처리 단계	내용
① 규정타석 필터	PA ≥ 300인 레코드만 사용
② 시간 순 정렬	선수 ID별로 Year 오름차순 정렬
③ Lag 변수 생성	현재 시즌 WAR를 기준으로 다음 시즌 WAR(next_WAR) 생성
④ 연속 시즌 검증	next_Year == Year + 1조건으로 연도 공백 제거
⑤ 최종 데이터셋	학습 1,689쌍 (-2022년) + 테스트 56쌍 (2023시즌)

4. 모델 / 서비스

4-1. 사용 방법 및 선택 근거

머신러닝 회귀 모델 3종 비교 (scikit-learn + XGBoost)

모델	선택 이유
Linear Regression	기준선(Baseline) 모델, 결과 해석이 용이함
Random Forest	비선형 관계 학습, 이상치 강건성, Feature Importance 제공
XGBoost	순차 부스팅으로 잔차 보정, 작은 데이터셋에서도 강력한 성능

딥러닝/LLM을 사용하지 않은 이유: 타구조 수치 데이터 회귀 문제로 해석 가능성이 높은 전통 ML이 적합하며, 학습 샘플 수(~1,700개)가 딥러닝에 충분하지 않다.

KNN (K-Nearest Neighbors) - 유사 선수 추천 전용

타격 지표 10개(AVG, OBP, SLG, OPS, HR, RBI, SB, BB, SO, wRC+)를 정규화 후 유클리드 거리 기준으로 가장 유사한 5명을 추천한다.

4-2. 입력 → 출력 흐름



4-3. 모델 성능 지표 (테스트셋: 2023시즌 → 2024시즌 예측)

모델	MAE	RMSE	R²
Linear Regression	1.146	1.479	0.292
XGBoost	1.277	1.570	0.202
Random Forest	1.265	1.618	0.152

최고 성능 모델: Linear Regression (R² = 0.292)

해석: MAE 약 1.15 WAR - 예측값이 실제 다음 시즌 WAR와 평균 1.15승 내외 오차를 보인다. 다음 시즌 WAR 예측은 부상, 이적, 나이에 따른 변화 등 모델이 학습할 수 없는 외부 요인이 많아 본질적으로 어려운 문제이며, R^2 0.3 수준은 이 과제에서 현실적인 성능이다.

Random Forest Feature Importance (상위 5개)

1. WAR (현시즌): 0.245
2. Age (나이): 0.062
3. BB (볼넷): 0.049
4. SO (삼진): 0.044
5. oWAR (공격 WAR): 0.044

→ 현재 시즌 WAR가 다음 시즌 WAR를 예측하는 가장 강력한 변수임이 확인됐다 (중요도 0.245, 2위 Age의 4배). 이는 선수의 실력이 단기간에 크게 변하지 않는다는 야구 통계의 일반 원칙과 일치한다. 나이(Age)가 2위를 차지한 것은 에이징 커브(성장·노화)를 모델이 포착하고 있음을 시사한다.

5. Streamlit 앱

5-1. 페이지 구성

app.py	← 홈 화면 (서비스 소개 + 데이터 미리보기)
pages/	
1_EDA.py	← 탐색적 데이터 분석
2_시각화.py	← 선수별 시각화
3_모델_서비스.py	← 예측 모델 + 유사 선수 추천
src/	
data_loader.py	← 데이터 로드 (캐싱)
features.py	← 전처리 + 피처 엔지니어링
data/	
kbo_batting_stats_by_season_1982-2025.csv	

5-2. 페이지별 주요 기능

홈 (app.py)

서비스 목적 소개 및 페이지 안내
핵심 수치 지표 카드 (전체 레코드, 선수 수, 수록 시즌, 규정타석 레코드 수)
최근 5년 데이터 미리보기 테이블

1_EDA 페이지

사이드바: 최소 PA 슬라이더(0-600) + 시즌 범위 슬라이더
① 데이터 기본 정보 + 결측치 현황

- 2_시각화 페이지

탭 2 - OPS·HR vs WAR: 산점도(OLS 추세선 포함), wRC+ vs WAR

탭 4 - 시즌 TOP: 시즌·N명 선택 → WAR 순위 테이블 + 가로 막대그래프

3_모델_서비스 페이지

탭 2 - WAR 예측: 성적 입력 폼(21개 변수) → 예상 WAR + 등급 판정 + 비슷한 WAR 선수 사례

탭 3 - 유사 선수 추천: 선수 선택 또는 직접 입력 → KNN 유사 선수 5명 + 레이더 차트 비교

<WAR 예측: 성적 입력 폼을 통한 예상 WAR 및 선수 등급 판정 도출>

[illegible]

주요 패키지: streamlit, pandas, numpy, plotly, scikit-learn, xgboost

1. WAR 예측의 핵심 변수는 현재 시즌 WAR 자체다: Feature Importance 분석에서 현시즌 WAR가 1위(0.245)로 나타나 선수의 실력이 단기간에 급변하지 않음을 입증했다.
2. 출루율(OBP)이 타율(AVG)보다 WAR와 더 강하게 연관된다: 출루율을 중시하는 세이버메트릭스의 주장이 KBO 데이터(OBP 0.767 > AVG 0.664)에서도 확인되었다.
3. wRC+는 WAR의 가장 강력한 단일 예측 지표다: 상관계수 0.849로 가장 높게 나타났다.
4. 나이(Age)와 WAR의 관계: 전체 데이터 수준에서 고령 선수일수록 평균 WAR가 낮아지는 경향(-0.067)이 관찰된다.
5. 예측의 불확실성: 부상, 이적, 팀 환경 변화 등 모델이 학습할 수 없는 요인으로 인해 다음 시즌 WAR 예측에는 본질적인 한계가 존재한다.

6-2. 한계 및 향후 과제

한계	내용
테스트셋 규모	규정타석 기준 적용 시 시즌당 56명 수준으로 작아 성능 평가의 분산이 큼
시즌 환경 차이	지명타자 운용, 외국인 선수 수, 10구단 확장 등 리그 환경 변화 미반영
포지션 미반영	포지션별(포수 vs 1루수 등) WAR 가중치 차이가 모델에 인코딩되지 않음
부상 정보 부재	부상, 군입대, 방출 등 다음 시즌 출전 가능 여부를 예측하는 외부 변수 부재

향후 개선 방향

- 포지션 원-핫 인코딩 추가 및 포지션별 별도 모델 학습
- 선수 에이징 커브(나이별 WAR 평균 궤적) 피쳐 추가
- 최근 3년치 성적의 가중 평균을 피쳐로 활용
- 시계열 교차 검증(TimeSeriesSplit) 도입 및 투수 데이터 확장 적용
- 투수 데이터까지 확장하여 팀 WAR 예측 서비스 구현